白酒行业2026年半年报问答知识库——实验结论

本项目选择方向A，基于10家白酒上市公司2026年半年度报告搭建财报问答知识库。选取公司包括贵州茅台、山西汾酒、舍得酒业、水井坊、老白干酒、今世缘、迎驾贡酒、口子窖、金徽酒和伊力特。

一、系统实现与交付说明

数据来源：上市公司公开披露的2026年半年度报告。

知识库构建流程：

1. 下载上市公司半年报PDF全文；
2. 提取文本，并保留公司、章节、页码等信息；
3. 对财报内容进行切块处理；
4. 建立语义向量检索和全文检索索引；
5. 使用混合检索召回候选内容，并通过rerank进行排序优化；
6. 通过问答页面生成带财报引用来源的回答。

最终构建了能够直接提问并显示财报出处的白酒财报问答助手。

二、实验设计与结果

为了检验知识库效果，共设计10道测试问题，其中8道为单公司问题，2道为跨公司全景问题。

测试结果：正确6题，部分正确2题，错误2题。

实验表明，当答案集中在某家公司的一两个财报片段中时，RAG能够较稳定地检索相关原文并生成带出处回答。

三、主要问题分析

1. 财务口径问题：财报中存在营业收入、营业总收入、母公司报表、合并报表等不同口径。例如贵州茅台不同指标名称接近，但统计范围不同，因此不能只检索数字，还需要判断指标口径。

2. 跨公司全景问题：比较多家公司营业收入增速、总结行业共同压力等问题，需要同时召回多个公司的材料。简单Top-K分块检索容易遗漏企业信息。

3. 上下文串扰问题：连续多轮问答中，如果目标公司切换，可能出现沿用上一问题公司内容的问题。需要加强公司标签过滤和检索约束。

四、实验结论

同一批财报中，单公司单指标事实查询适合RAG，因为答案通常集中在少量财报片段；跨公司全景分析更容易因多文档召回不足、财务口径差异和表格结构丢失导致错误。

后续优化方向：

1. 增加公司标签过滤；
2. 将关键财务指标结构化存储；
3. 对不同公司分别检索后再汇总；
4. 使用Agent式多轮检索提升跨文档分析能力。

五、交付内容说明

代码仓库包含知识库构建流程、检索配置和运行说明；页面截图展示问答效果；本PDF总结实验设计、测试结果以及RAG适用边界。